

# Arquitectura del proyecto

La arquitectura del proyecto está basada en un proceso ETL (Extract, Transform, Load) desarrollado en SQL Server Integration Services (SSIS). Su objetivo principal es automatizar la integración de información proveniente de tres archivos CSV (Clientes, Productos y Ventas), garantizando que únicamente los datos válidos sean almacenados en SQL Server, mientras que los registros con errores son separados para su revisión.

El proyecto sigue una arquitectura por componentes, donde cada uno tiene una responsabilidad específica dentro del flujo de procesamiento.

## 1. Fuentes de datos (Data Sources)

La arquitectura comienza con la lectura de tres archivos CSV ubicados en la carpeta de entrada:

- Clientes.csv
- Productos.csv
- Ventas.csv

Estos archivos representan la fuente de información del sistema y contienen datos sin procesar, los cuales pueden incluir errores, valores nulos, formatos incorrectos o información inconsistente.

## 2. Control Flow (Coordinador del proceso)

El Control Flow funciona como el componente central de la arquitectura, encargado de coordinar todas las actividades del paquete ETL.

Su función es ejecutar cada etapa en el orden correcto para asegurar que la información esté disponible cuando sea necesaria.

El flujo general es el siguiente:



Cada una de estas actividades es independiente, pero están conectadas mediante restricciones de precedencia para garantizar que una tarea solo inicie cuando la anterior haya finalizado correctamente.

### 3. Componente de carga de Clientes

Este componente procesa el archivo Clientes.csv.

Su arquitectura está formada por varios elementos especializados:

- **Origen CSV**  
Lee todos los registros del archivo.
- **Derived Column (Limpieza)**  
Elimina espacios innecesarios.  
Convierte nombres a mayúsculas.  
Sustituye valores nulos por información predeterminada.
- **Data Conversion**  
Convierte los tipos de datos del archivo CSV al formato requerido por SQL Server.
- **Conditional Split**  
Separa los clientes activos de los inactivos.

Los registros válidos continúan hacia la tabla DimCliente, mientras que los registros rechazados se almacenan en un archivo de errores.

Este componente garantiza que únicamente clientes válidos puedan utilizarse posteriormente durante la carga de ventas.

## 4. Componente de carga de Productos

Este módulo procesa el archivo Productos.csv.

Su función consiste en validar que cada producto cumpla con las reglas del negocio.

La arquitectura interna está compuesta por:

- Lectura del archivo CSV.
- Limpieza de texto.
- Conversión de datos.
- Validación mediante Conditional Split.

Las reglas verifican que:

- El producto esté activo.
- El precio sea mayor que cero.
- El costo sea mayor que cero.
- La categoría pertenezca al catálogo permitido.

Los productos válidos son almacenados en DimProducto, mientras que aquellos que incumplen alguna condición son enviados al archivo Errores\_Productos.csv.

## 5. Componente de carga de Ventas

Este es el componente más importante y complejo del proyecto, ya que integra la información previamente cargada de clientes y productos.

Su arquitectura está formada por los siguientes elementos:

- **Origen CSV**  
Lee todas las ventas registradas en el archivo.
- **Data Conversion**  
Convierte datos de texto a:
  - Enteros
  - Decimales
  - Fechas
- **Derived Column**  
Realiza la transformación de fechas y prepara la información para el procesamiento.

- **Conditional Split**

Valida que:

- Cantidad > 0
- Precio Unitario > 0
- Fecha válida

- **Lookup Cliente**

Consulta la tabla DimCliente para comprobar que el cliente exista.  
Si no existe, el registro es rechazado.

- **Lookup Producto**

Consulta la tabla DimProducto para validar que el producto exista.  
Si no existe, la venta también es rechazada.

- **Derived Column (Métricas)**

Calcula automáticamente:

- Subtotal
- IVA
- Total

- **Destino SQL Server**

Las ventas correctas son almacenadas en la tabla FactVentas.

Gracias a esta arquitectura se garantiza la integridad referencial entre las tablas de dimensiones y la tabla de hechos.

## 6. Base de datos SQL Server

Una vez finalizado el proceso ETL, la información queda organizada en una arquitectura tipo Data Warehouse, compuesta por:

| Tabla              | Función                                                                                                        |
|--------------------|----------------------------------------------------------------------------------------------------------------|
| <b>DimCliente</b>  | Almacena los clientes válidos y activos.                                                                       |
| <b>DimProducto</b> | Contiene únicamente los productos válidos.                                                                     |
| <b>FactVentas</b>  | Guarda todas las ventas junto con Subtotal, IVA y Total calculados.                                            |
| <b>LogErrores</b>  | Registra información sobre registros rechazados y errores detectados.                                          |
| <b>LogProceso</b>  | Almacena auditoría del proceso ETL, incluyendo hora de inicio, hora de fin y cantidad de registros procesados. |

## 7. Componente de postproceso

Una vez que todos los datos han sido cargados correctamente, el paquete ejecuta una etapa final encargada de administrar los archivos procesados.

Las actividades realizadas son:

- Mover los archivos CSV desde la carpeta de entrada hacia la carpeta de procesados.
- Generar un archivo ZIP con los archivos procesados.
- Mantener separados los archivos de errores generados durante la ejecución.

## Funcionamiento general de la arquitectura

La arquitectura completa puede entenderse como una línea de producción de datos. Primero se extraen los tres archivos CSV, posteriormente cada conjunto de datos pasa por procesos de limpieza, estandarización y validación. Después se verifica la integridad de la información mediante búsquedas de clientes y productos existentes, se calculan automáticamente las métricas de las ventas y finalmente los registros válidos se almacenan en SQL Server. El sistema genera archivos con los registros rechazados y organiza automáticamente los archivos procesados, asegurando una carga de datos confiable, trazable y completamente automatizada.