

Explicación del proceso ETL

El proceso ETL (Extract, Transform and Load) implementado en el paquete CargaVentas1.dtsx tiene como objetivo integrar información proveniente de tres archivos CSV, depurarla, validarla y almacenarla en una base de datos SQL, garantizando la calidad e integridad de los datos antes de que sean utilizados para análisis o reportes.

El proceso puede compararse con una línea de producción industrial, donde la materia prima son los archivos CSV con información sin procesar, la etapa de producción corresponde a la limpieza y validación de los datos, y el producto final son registros confiables almacenados en la base de datos junto con un registro de auditoría de todo el proceso.

Fase de extracción

La primera etapa consiste en leer completamente los tres archivos CSV ubicados en la carpeta de entrada:

- Clientes.csv
- Productos.csv
- Ventas.csv

Cada archivo es procesado por separado mediante un flujo de datos independiente. Durante esta etapa únicamente se extraen los registros, sin realizar modificaciones, obteniendo la información tal como fue generada por el sistema origen.

Flujo principal

El Control Flow es el encargado de coordinar toda la ejecución del paquete ETL. Cada actividad se ejecuta de manera secuencial para asegurar que los datos dependientes existan antes de procesar la siguiente etapa.

El proceso inicia registrando en la tabla LogProceso la fecha y hora de inicio de la ejecución. Posteriormente se ejecutan de forma ordenada las cargas de clientes, productos y ventas.

Una vez finalizadas todas las cargas, el paquete registra estadísticas como el número de registros procesados, inserciones realizadas, fecha de finalización y estado del proceso. Finalmente ejecuta un postproceso encargado de mover los archivos procesados a una carpeta histórica y generar un archivo comprimido (.zip) con respaldo de la información procesada.

Transformación de Clientes

El flujo de clientes comienza leyendo todos los registros del archivo Clientes.csv, posteriormente se aplica una transformación de limpieza mediante un componente Derived Column, donde se normalizan los nombres eliminando espacios innecesarios y convirtiendo el texto a mayúsculas, también se sustituyen valores nulos, por ejemplo, cuando una ciudad no existe se reemplaza por el texto "SIN CIUDAD".

Después se ejecuta una conversión de tipos de datos (Data Conversion) para adaptar la información al formato requerido por SQL Server, posteriormente un componente Conditional Split valida que únicamente los clientes activos (Activo = 1) continúen el flujo. Los clientes inactivos son enviados automáticamente a un archivo Errores_Clientes.csv para su revisión.

Finalmente, los registros válidos son almacenados en la tabla DimCliente.

Transformación de Productos

El flujo de productos inicia leyendo completamente el archivo Productos.csv.

Durante la limpieza se normalizan los textos convirtiendo las categorías y nombres a mayúsculas para mantener uniformidad en la información.

Después se ejecuta un filtro de validación donde solamente son aceptados los productos que cumplen simultáneamente las siguientes reglas:

- El producto debe estar activo.
- El precio debe ser mayor que cero.
- El costo debe ser mayor que cero.
- La categoría debe pertenecer al catálogo autorizado:
 - Computo
 - Accesorios
 - Muebles
 - Redes
 - Almacenamiento
 - Infraestructura

Los productos que pertenecen a categorías no válidas, como Ropa, Deportes u Oficina, son rechazados y almacenados en el archivo Errores_Productos.csv.

Los registros válidos son cargados en la tabla DimProducto.

Transformación de Ventas

Inicialmente se leen todos los registros del archivo Ventas.csv.

Posteriormente se convierten los tipos de datos para transformar valores de texto en números enteros, decimales y fechas compatibles con SQL Server.

Una vez convertidos los datos, se validan las siguientes condiciones:

- La cantidad debe ser mayor que cero.
- El precio unitario debe ser mayor que cero.
- La fecha de venta debe existir.

Después comienzan las validaciones referenciales utilizando componentes Lookup.

Primero se verifica que el cliente exista previamente en la tabla DimCliente.

Posteriormente se valida que el producto exista en la tabla DimProducto.

Si cualquiera de estas búsquedas falla, el registro es rechazado para evitar inconsistencias en la base de datos.

Las ventas válidas continúan hacia una transformación donde se calculan automáticamente las métricas de negocio:

- $\text{Subtotal} = \text{Cantidad} \times \text{Precio Unitario}$
- $\text{IVA} = \text{Subtotal} \times 0.16$
- $\text{Total} = \text{Subtotal} + \text{IVA}$

Finalmente, toda la información es almacenada en la tabla FactVentas.

Carga

Después de completar todas las transformaciones y validaciones, la información es almacenada en SQL Server dentro del modelo dimensional.

Las tablas generadas son:

Tabla	Información almacenada
DimCliente	Clientes activos y limpios
DimProducto	Productos válidos con categorías autorizadas
FactVentas	Ventas con Subtotal, IVA y Total calculados
LogErrores	Registro de datos rechazados durante el proceso
LogProceso	Auditoría completa de la ejecución del paquete

Manejo de errores

Durante toda la ejecución del ETL se implementa un mecanismo de control de calidad que separa los registros incorrectos de los registros válidos.

Los datos que no cumplen alguna regla de negocio no detienen el proceso, en cambio, son enviados automáticamente a archivos de errores para facilitar su revisión posterior.

De esta manera se garantiza que únicamente la información confiable sea almacenada en la base de datos.

Postproceso

Al concluir la carga de información, el paquete realiza automáticamente tareas administrativas.


Los archivos CSV originales son movidos desde la carpeta de entrada hacia la carpeta Procesados, evitando que vuelvan a cargarse en futuras ejecuciones.

Además, se genera un archivo comprimido con fecha y hora que funciona como respaldo histórico del proceso ejecutado.

La estructura final queda organizada de la siguiente manera:

- **data/entrada/** queda vacía después del procesamiento.
- **data/procesados/** contiene los archivos CSV procesados y un archivo ZIP con respaldo.
- **data/errores/** almacena los registros rechazados durante la validación.

Diagrama



Conclusión

El paquete ETL implementado automatiza completamente la integración de datos provenientes de archivos CSV. Durante su ejecución extrae la información, realiza procesos de limpieza, estandarización y validación, verifica la integridad referencial entre clientes, productos y ventas, calcula indicadores de negocio como Subtotal, IVA y Total, almacena únicamente los registros válidos en SQL Server y registra tanto los errores como las estadísticas de ejecución. Finalmente organiza los archivos procesados y genera respaldos automáticos, garantizando un proceso confiable, repetible y preparado para el análisis posterior de la información.